

Deteção Automática de Incêndios através do uso de CNN

Nuno Filipe Machado Lopes da Silva

**Dissertação para obtenção do Grau de Mestre em
Engenharia Informática, Área de Especialização em
Sistemas Gráficos e Multimédia**

Orientador: Ana Maria Madureira

Co-Orientador: João Carlos Ferreira

Porto, Outubro 2022

Resumo

Os incêndios são um grande problema cada vez mais relevante da nossa sociedade e constituem verdadeiras calamidades que atingem proporções alarmantes e que acarretam consequências graves em vários domínios, dos quais se destacam o ambiente, a economia e o turismo, além de constituírem uma situação de perigo para as populações locais e seus bens.

As florestas são de extrema importância não só para o ambiente, por serem imprescindíveis ao equilíbrio da fauna e flora, destacando-se também o seu papel na produção de oxigénio para além de reduzirem o impacto cada vez mais intenso do calor. Por outro lado, também a economia é um fator a ter em conta, dados os recursos que dependem das zonas florestais.

Deste modo, a rápida deteção dos incêndios torna-se crucial por forma a extingui-los, de modo a evitar danos, daí que a criação de instrumentos que permitam combatê-los a ‘priori’ é fundamental.

Com este projeto, pretende-se o desenvolvimento de um sistema de classificação, com base em aprendizagem automática, *Deep Learning* e processamento de imagem, que consiga detetar os incêndios com exatidão, processo realizado com recurso a imagens, ultrapassando problemas que possam impedir o seu efetivo reconhecimento, como, por exemplo, nevoeiro, nuvens e diferentes tipos de fumos. Espera-se que, com a concretização deste trabalho, aliado aos mecanismos de defesa nacional já existentes, seja possível reforçar e melhorar a prevenção desta catástrofe.

Palavras-chave: Incêndio, *Deep Learning*, CNN, Deteção de incêndios

Abstract

Fires are a major problem of our society and are real calamities that reach alarming proportions and have serious consequences in various areas, including the environment, the economy and tourism, besides being a dangerous situation for local populations and their property.

Forests are extremely important not only for the environment, as they are essential to the balance of fauna and flora, but also for their role in the production of oxygen and in reducing the increasingly intense impact of heat. On the other hand, the economy is also a factor to be taken into account, given the resources that depend on forest areas.

Thus, the rapid detection of fires becomes crucial in order to extinguish them, in order to avoid damage, so the creation of instruments that allow fighting them a 'priori' is fundamental.

With this project, we intend to develop an algorithm, based on machine learning, Deep Learning and image processing, that can accurately detect fires, a process carried out using photos, overcoming problems that may prevent its effective recognition, such as fog, clouds and different types of smoke. It is hoped that with the implementation of this work, allied to the already existing national defense mechanisms, it will be possible to strengthen and improve the prevention of this catastrophe.

Keywords: forest fire, *Deep Learning*, *CNN*

Agradecimentos

Ao longo do processo de elaboração desta dissertação existiram pessoas fundamentais para a sua concretização. A essas pessoas eu gostava de deixar o meu agradecimento.

Em primeiro lugar, quero agradecer aos meus pais pelo apoio, por me darem toda a motivação e força necessária para conseguir concluir esta etapa. Quero agradecer do fundo do meu coração, especialmente, à minha namorada Catarina, mas também a todos os meus familiares pelo carinho, apoio e compreensão. Estarei eternamente grato por toda a ajuda e palavras de incentivo. Um agradecimento especial à orientadora e coorientador, Ana Maria Madureira e João Carlos Ferreira, pela disponibilidade para se reunirem comigo e pelo acompanhamento dado. O seu acompanhamento constante foi imprescindível para o culminar deste percurso.

Por fim, o meu profundo e sentido agradecimento a todas as pessoas que contribuíram para a finalização desta dissertação.

Índice

1	Introdução	1
1.1	Contexto	1
1.1.1	Dados sobre a ocorrência de incêndios da União Europeia e de Portugal	2
1.1.2	Dados sobre a desflorestação a nível global	9
1.2	Problema	13
1.3	Objetivos	13
2	Estado de Arte	15
2.1	Machine Learning	15
2.1.1	Aprendizagem supervisionada	15
2.1.2	Aprendizagem supervisionada	16
2.1.3	Aprendizagem de reforço	16
2.2	Deep Learning	16
2.3	Convolutional Neural Network	17
2.3.1	Arquitetura	18
2.3.1.1	Camada de Ativação	19
2.3.1.2	Camada de Classificação	21
2.4	Estado da Arte de Sistemas de Reconhecimento	21
2.4.1	R-CNN	22
2.4.1.1	Problemas Associados com o R-CNN	22
2.4.2	Fast R-CNN	23
2.4.3	Faster R-CNN	23
2.4.4	YOLO	25
2.4.4.1	Yolo v1	25
2.4.4.2	Yolo v2	26
2.4.4.3	Yolo v3	27
2.5	Desafios encontrados na deteção de objetos	27
2.5.1	Overfitting	27
2.5.2	Class Imbalance	28
2.5.3	Exploding Gradient e Vanishing Gradient	29

2.6	Soluções existentes	29
3	Análise de Valor	31
3.1	Identificação da oportunidade	31
3.2	Análise da Oportunidade	35
3.3	Fast	36
3.3.1	Definição	36
3.3.2	Benefícios	36
3.3.3	Diagrama	37
4	Experimentação e Avaliação	39
4.1	Objetivo	39
4.2	Metodologia de Avaliação	39
4.3	Requisitos	40
4.4	Dataset	41
4.4.1	Exemplos das imagens do dataset	42
4.5	Configuração do modelo atual	46
4.5.1	Filtros do modelo	46
4.5.2	Treino do modelo	48
4.5.3	Arquitetura do modelo	49
4.6	Modelos Pré-treinados	49
4.6.1	Análise dos Resultados	51
5	Conclusão	59
5.1	Trabalho futuro	61
	Referências	63

Lista de Figuras

Figura 1 - Gráfico da área ardida dos países da união europeia [27]	5
Figura 2 - Figura com o número de incêndios dos países da união europeia [27]	7
Figura 3 - Figura com gráfico da perda de floresta primária entre 2002 e 2021 REF [29]	10
Figura 4 - Figura com gráfico da perda de floresta nos diversos países do mundo [30]	10
Figura 5 - Figura relativa às emissões de CO ₂ , gases emitidos pela UE [70]	11
Figura 6 - Figura relativa às emissões cumulativas de MTCO ₂ , pela UE [70]	11
Figura 7 - Processo de max-pooling [24]	19
Figura 8 - Processo RELU [17]	20
Figura 9 - Gráfico da função matemática que exprime o RELU [18]	20
Figura 10 - Funcionamento do R-CNN [22]	22
Figura 11 - Funcionamento do Fast R-CNN [22]	23
Figura 12 - Funcionamento do Faster R-CNN [22]	24
Figura 13 - Yolo Detector [13]	25
Figura 14 - Yolo v1 [12]	26
Figura 15 - Loss e Accuracy em situação de Overfitting [26]	28
Figura 16 - Diagrama FAST	37
Figura 17 - Diagrama da Metodologia	39
Figura 18 - Exemplo de Floresta	43
Figura 19 - Exemplo de Nuvens	43
Figura 20 - Exemplo de Nevoeiro	44
Figura 21 - Exemplo de Fumo de Incêndio	44
Figura 22 - Exemplo de tochas	44
Figura 23 - Exemplo de Pôr de Sol	45
Figura 24 - Exemplo de Pôr de Sol	45
Figura 25 - Filtros do modelo atual	47
Figura 26 - Imagem do gráfico de treino do modelo	48
Figura 27 - Valores da análise de Modelos Pré-Treinados [33]	50
Figura 28 - Exemplo de presença de fogo	52
Figura 29 - Exemplo da identificação do sistema acerca da Figura 30	52
Figura 30 - Exemplo de presença de fumo de um incêndio	53
Figura 31 - Exemplo do reconhecimento do sistema acerca da Figura 32	53
Figura 32 - Exemplo de presença de um pôr do sol	54
Figura 33 - Exemplo do reconhecimento do sistema acerca da Figura 34	54
Figura 34 - Exemplo da presença de um campo florestal	55
Figura 35 - Exemplo do reconhecimento do sistema acerca da Figura 36	55
Figura 36 - Exemplo da presença de fumo	56
Figura 37 - Exemplo do reconhecimento do sistema acerca da Figura 38	56
Figura 38 - Exemplo de data augmentation [31]	62

Lista de Tabelas

Tabela 1 - Número de incêndios rurais e a sua área ardida em Portugal, durante 2012 a 2021 [32]	2
Tabela 2 - Média da área ardida por cada incêndio rural em hectares, durante o período 2012 a 2021 [32]	3
Tabela 3 - Valores respetivos à área ardida dos países da união europeia [27]	6
Tabela 4 - Tabela com os respetivos valores sobre o número de incêndios nos países da União Europeia [27]	8
Tabela 5 - Distribuição mensal dos incêndios [25]	32
Tabela 6 - Distribuição anual dos incêndios e comparação da área ardida [25]	33
Tabela 7 - Causas dos incêndios [25]	34
Tabela 8 - Configuração (Treino - NoFire)	41
Tabela 9 - Configuração (Treino - Fire)	41
Tabela 10 - Configuração (Validação - NoFire)	42
Tabela 11 - Configuração (Validação - Fire)	42
Tabela 12 - Configuração (Validação - Fire)	51

Acrónimos e Símbolos

Lista de Acrónimos

ANPC	Autoridade Nacional de Proteção Civil
CDOS	Comando Distrital de Operações de Socorro
CNN	<i>Convolutional Neural Network</i>
EFFIS	European Forest Fire Information System
FFF	Forest Fire Finder
GNR	Guarda Nacional Republicana
GPU	Graphics Processing Unit
IA	Inteligência Artificial
ICNF	<i>Instituto da Conservação da Natureza e das Florestas</i>
KT	Kiloton
R-CNN	<i>Region-based Convolutional Neural Networks</i>
RELU	<i>Rectified Linear Unit</i>
ROI	<i>Region of Interest</i>
RPN	<i>Region Proposal Network</i>
SVM	<i>Support Vector Machine</i>
YOLO	<i>You Only Look Once</i>

Lista de Símbolos

CO₂	Dióxido de carbono
MTCO₂	toneladas métricas de dióxido de carbono

1 Introdução

Esta dissertação visa explicitar qual a metodologia, protocolos, raciocínios e decisões efetuadas ao longo do desenvolvimento deste trabalho de mestrado.

Deste modo, far-se-á uma breve introdução a cada tema retratado em cada um dos capítulos:

- no capítulo 2, foram expostas as diversas técnicas e tecnologias relevantes para o processo, apresentando uma visão sobre os temas que se encontram diretamente relacionadas com os tópicos envolvidos no contexto do problema atual;
- no capítulo 3, é retratado o valor e a importância que esta dissertação contribui para a sociedade;
- no capítulo 4, foi desenvolvido a Experimentação e Avaliação, que explica como a experimentação irá ser efetuada e o modo como se avalia o desempenho do sistema.

1.1 Contexto

Os incêndios florestais são encarados como catástrofes naturais, não só devido ao facto de se desenvolverem num ambiente natural, como também por a sua ocorrência e a sua propagação estarem dependentes de causas naturais, como o excesso de calor e os ventos.

Por estes factos, os incêndios constituem uma realidade com que o Homem aprendeu a conviver desde sempre, mas fatores especialmente ligados à intervenção humana e às consequências do aquecimento global têm sido cada vez mais frequentes e as suas consequências são cada vez mais catastróficas a vários níveis.

O impacto destes poderá ser muito superior a uma área ardida, visto que também traz associado ao mesmo um conjunto de outras consequências gravosas, tais como:

- a destruição de bens, a perda de solo, a destruição dos habitats dos animais, o impacto na economia e turismo na região incidente, as emissões de CO₂, a destruição

de fauna e da flora, influenciado negativamente o equilíbrio que os ecossistemas tanto precisam.

Visto que existem variados fatores que influenciam a forma como um incêndio se alastra, o seu combate numa fase inicial torna-se premente, no entanto, é do conhecimento geral que em áreas de difícil acesso, os profissionais terão obstáculos que irão dificultar o acesso ao local e o seu trabalho, por isso, o tempo torna-se crucial no combate a esta calamidade. Assim, todos os segundos contam e estes podem ser diminuídos drasticamente, começando pela identificação do incêndio numa fase inicial.

1.1.1 Dados sobre a ocorrência de incêndios da União Europeia e de Portugal

Tabela 1 - Número de incêndios rurais e a sua área ardida em Portugal, durante 2012 a 2021 [32]

Ano	Incêndios rurais (nº)	Área ardida (ha)			
		Povoamentos	Matos	Agrícola	Total
2012	19071	27500	46727	5631	79858
2013	16114	45892	77332	7169	130393
2014	7880	7482	7487	2512	17481
2015	16034	22084	35614	3420	61118
2016	10942	65671	58139	4705	128515
2017	14366	127520	91006	17959	236485
2018	8525	19815	14706	2402	36923
2019	7799	14654	10162	3700	28516
2020	6903	15926	17534	5275	38735
2021	6459	7897	15155	2803	25855
2022	9701	54328	42367	9944	106639
Média 2012-2021	11409	35444	37386	5558	78388

O relatório mais recente providenciado pelo ICNF, Instituto da Conservação da Natureza e das Florestas, indica, através da Tabela 1, que, durante o período compreendido entre 1 de Janeiro e 31 de Agosto do ano de 2022, ocorreram 9701 incêndios rurais, tendo estes causado 106 639 hectares de área ardida, sendo esta área composta por 54 328 hectares de povoamento, 42 367 hectares de mato e 9 944 hectares de campos agrícolas.

“Comparando os valores do ano de 2022 com o histórico dos 10 anos anteriores, assinala-se que se registaram menos 15% de incêndios rurais e mais 36% de área ardida relativamente à média anual do período”. “O ano de 2022 apresenta, até ao dia 31 de agosto, o 6.º valor mais elevado em número de incêndios e o 4.º valor mais elevado de área ardida, desde 2012.”

Tabela 2 - Média da área ardida por cada incêndio rural em hectares, durante o período 2012 a 2021 [32]

Ano	Incêndios rurais (nº)							Área ardida média por incêndio rural (ha)
]0 - 1[ha]1 - 10[ha]10 - 20[ha]20 - 50[ha]50 - 100[ha]100 - 1000[ha]1000 - ...[ha	
2012	15399	3027	246	218	85	91	5	4.2
2013	13407	2132	166	175	76	131	27	8.1
2014	6772	919	66	70	31	20	2	2.2
2015	12993	2500	212	172	68	81	8	3.8
2016	9005	1439	161	122	67	129	19	11.7
2017	11524	2204	210	188	84	122	34	16.5
2018	7424	941	76	60	11	12	1	4.3
2019	6640	891	106	89	37	35	1	3.7
2020	6039	677	60	56	26	38	7	5.6
2021	5291	869	124	102	45	26	2	4
2022	7957	1285	164	141	61	77	16	11
Média anual 2012-2021	9449	1560	143	125	53	69	11	6.9

A Tabela 2, evidencia o número de incêndios classificando-os mediante a área ardida em hectares relativamente a cada ano, estudando este as dimensões dos incêndios. Após analisar os valores correspondentes ao ano atual e comparando estes em relação à média, conseguimos confirmar que os valores atuais se encontram bastante acima da média em quase todas as categorias, exceto as duas primeiras. A área ardida média por incêndio rural, medido em hectares, foi de 11, enquanto a média é de 6,9 hectares.

Através dos dados das tabelas apresentadas, constata-se que, não obstante uma menor ocorrência de incêndios em 2022, tal situação não configura um sinónimo de progresso positivo na prevenção daqueles, uma vez que, na realidade, Portugal, em relação ao período compreendido entre 2012 e 2022, registou mais 36% de área ardida. Para além disso, consegue-se verificar que a área ardida medida em hectares por cada incêndio rural atingiu um valor de 11 hectares, valor muito acima da média (6,9 hectares).

O *EFFIS*, European Forest Fire Information System, foi criado pela Comissão Europeia. Este organismo é constituído por diversas entidades e administrações nacionais de incêndios e possui como objetivo a prestação de serviços de apoio contra incêndios na UE e nos seus países vizinhos [27].

Neste capítulo vamos tirar partido dos dados retirados e publicados no portal do *EFFIS* para, a partir deste, demonstrar diversas estatísticas e informações relativamente a dados relativos aos incêndios, para que, no fim, seja possível verificar a diferença entre os dados dos diversos países europeus e os dados de Portugal.

Como é possível verificar através dos dados fornecidos pelo *EFFIS* na Figura 1, Portugal é o país da União Europeia com a maior percentagem de área ardida durante o período compreendido entre 2006 e 2021.

Sendo mais preciso, com base nos dados apresentados na Tabela 3, no período anteriormente mencionado, verificou-se que em Portugal ardeu 1.0517% do seu território.

Para além disso, é possível verificar na Tabela 3, que a média de área ardida era de 1.0517% e este ano 2022, superou a média, tendo ardido 1,13%, um número superior. É de relembrar, que o ano ainda não acabou, pelo que o número só aumentara.

Comparando os resultados com outros países, conseguimos verificar que entre 2006 e 2021, para além de estar em primeiro lugar em termos de área ardida, o segundo país com a maior taxa de área ardida, Roménia, apresenta uma percentagem de 0.0601, o que se traduz no facto de Portugal possuir quase o dobro da área ardida. para além disso, este ano até agora, Portugal tem 1,13% do seu território ardido, enquanto a Roménia teve 0,63, comprovando novamente o mesmo caso anterior [28].




Figura 1 - Gráfico da área ardida dos países da união europeia [27]

Tabela 3 - Valores respetivos à área ardida dos países da união europeia [27]

ISO3	Country	Country area (ha)	Year 2022 (ha)	Annual Avg. 2006 - 2021 (ha)	(*) Year 2022 (%)	(*) Annual Avg.2006 - 2021 (%)
AUT	Austria	8385823	1016	17.38	0.01	0.00
BEL	Belgium	3070746	382	214.13	0.01	0.01
BGR	Bulgaria	11158767	12702	9733.94	0.11	0.09
HRV	Croatia	5707857	32972	13113.06	0.58	0.23
CYP	Cyprus	571965	2344	1665.38	0.41	0.29
CZE	Czechia	7883578	1436	9.06	0.02	0.00
DNK	Denmark	4314484	341	56.50	0.01	0.00
EST	Estonia	4548988		24.06		0.00
FIN	Finland	33694010	160	191.94	0.00	0.00
FRA	France	54951621	64656	9825.69	0.12	0.02
DEU	Germany	35783935	4293	417.00	0.01	0.00
GRC	Greece	13257480	22260	44640.13	0.17	0.34
HUN	Hungary	9305287	7287	338.69	0.08	0.00
IRL	Ireland	7036676	2900	3261.38	0.04	0.05
ITA	Italy	30075506	53845	53961.38	0.18	0.18
LVA	Latvia	6471010	171	180.81	0.00	0.00
LTU	Lithuania	6501683		17.44		0.00
LUX	Luxembourg	258155		0.00		0.00
MLT	Malta	32336		4.13		0.01
NLD	Netherlands	3766581	274	96.81	0.01	0.00
POL	Poland	31240006	528	402.63	0.00	0.00
PRT	Portugal	9187803	104077	96625.44	1.13	1.05
ROU	Romania	23833860	149278	14313.38	0.63	0.06
SVK	Slovakia	4909927	317	12.50	0.01	0.00
SVN	Slovenia	1998091	4388	103.25	0.22	0.01
ESP	Spain	50604375	297362	66965.13	0.59	0.13
SWE	Sweden	45004727	266	2544.25	0.00	0.01




Figura 2 - Figura com o número de incêndios dos países da união europeia [27]

Tabela 4 - Tabela com os respetivos valores sobre o número de incêndios nos países da União Europeia [27]

IS03	Country	Country area (ha)	Year 2022	Annual Avg. 2006 - 2021
AUT	Austria	8385823	5	0.19
BEL	Belgium	3070746	4	0.94
BGR	Bulgaria	11158767	72	23.31
HRV	Croatia	5707857	150	31.81
CYP	Cyprus	571965	9	5.50
CZE	Czechia	7883578	1	0.06
DNK	Denmark	4314484	6	0.69
EST	Estonia	4548988		0.44
FIN	Finland	33694010	3	1.19
FRA	France	54951621	280	58.69
DEU	Germany	35783935	32	3.81
GRC	Greece	13257480	48	54.75
HUN	Hungary	9305287	44	1.75
IRL	Ireland	7036676	20	10.69
ITA	Italy	30075506	437	263.13
LVA	Latvia	6471010	2	0.69
LTU	Lithuania	6501683		0.31
LUX	Luxembourg	258155		0.00
MLT	Malta	32336		0.13
NLD	Netherlands	3766581	6	0.44
POL	Poland	31240006	7	0.69
PRT	Portugal	9187803	254	203.88
ROU	Romania	23833860	716	49.31
SVK	Slovakia	4909927	4	0.13
SVN	Slovenia	1998091	4	0.69
ESP	Spain	50604375	416	174.06
SWE	Sweden	45004727	5	7.56

Com base nos últimos dados fornecidos através da Figura 2 e a Tabela 4, conseguimos verificar que Portugal, durante o período de 2006 a 2021, foi o segundo país da UE com maior número de incêndios. Com base na Tabela 4, verifica-se que Itália teve 263 fogos, Portugal 203 e Espanha 174; em quarto lugar, surge a Grécia, com 54, verificando-se uma grande discrepância entre este caso e os países que foram referidos anteriormente [28]. Contudo, em 2022, Portugal encontra-se no quinto lugar desta tabela, tendo tido até agora 254 incêndios, mais 51 até agora do que a sua média.

Deste modo, conclui-se que Portugal, numa área tão sensível como os incêndios, com todas as consequências negativas inerentes, quando comparado com os outros países da UE, apresenta valores muito preocupantes, tanto no que diz respeito à extensão de área ardida, como em relação ao número de incêndios, ocupando durante o período em análise os piores lugares.

1.1.2 Dados sobre a desflorestação a nível global

A nível global em 2019, perderam-se na zona tropical 11,9 milhões de hectares de arvoredo. Da totalidade dos hectares perdidos para o incêndio neste ano, 3,8 milhões de hectares, quase um terço do total pertenciam às florestas primárias tropicais, que são fundamentais para a biodiversidade. Esta perda é o equivalente a perder um campo de futebol de floresta primária a cada 6 segundos durante todo o ano [29].

Dois anos mais tarde, em 2021, ocorreu uma perda de 11,1 milhões de hectares perdidos de árvores. Destes hectares, 3,75 hectares de floresta primária foram perdidos para os incêndios florestais. Para além disso, esta perda teve como consequência a emissão de 2,5Gt de emissões de dióxido de carbono. Para ter uma comparação, estas mesmas emissões correspondem às emissões anuais de combustíveis fósseis da Índia [30].

Fornecendo dados mais específicos, em 2019, a perda de floresta primária aumentou 2,8%, quando comparado com o ano anterior, 2018. Nos anos seguintes, de 2019 a 2020, houve um aumento de perda da floresta primária em cerca de 12%. E, por fim, de 2020 a 2021, houve uma redução de 11% de perda de floresta primária.

Para além disso, é possível comprovar, através da informação presente na Figura 4, que Portugal é um dos países com maior perda de floresta a nível global.

TROPICAL PRIMARY FOREST LOSS, 2002-2021




Figura 3 - Figura com gráfico da perda de floresta primária entre 2002 e 2021 REF [29]

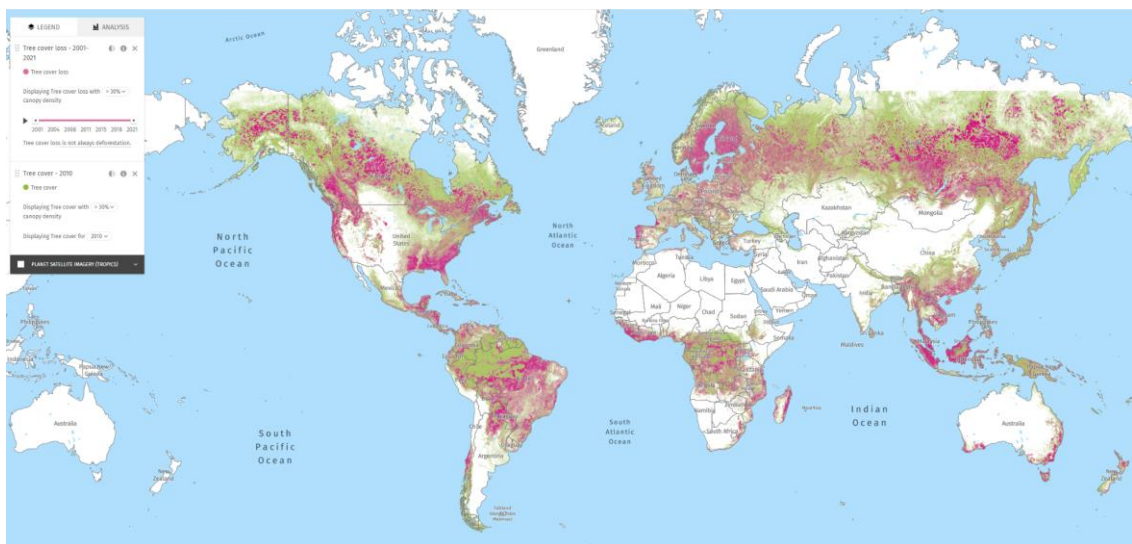


Figura 4 - Figura com gráfico da perda de floresta nos diversos países do mundo [30]




Figura 5 - Figura relativa às emissões de CO₂, gases emitidos pela UE [70]




Figura 6 - Figura relativa às emissões cumulativas de MTCO₂, pela UE [70]

Através dos dados presentes na Figura 5, podemos concluir que nos países pertencentes à União Europeia, durante o ano de 2022, as emissões de dióxido de carbono, CO₂, apresentam valores muito elevados, considerando a média dos últimos 18 anos. Através dos dados fornecidos pelo portal da EFFIS, pode-se constatar que, durante este ano de 2022, as emissões de CO₂ chegaram mesmo a atingir durante alguns períodos valores bastante superiores. Sendo o maior pico deste ano em Julho, atingiu valores de 5294 Kt, *Kiloton*, de emissões, enquanto o maior pico da média destes, entre o período de 2003 a 2021, tinha apenas apresentado 1871 Kt de CO₂, sendo esta diferença abismal pois estamos a falar de um aumento em 282%.

Para além disso, acontece o mesmo em relação às emissões acumuladas de dióxido de carbono (CO₂), e encontramos-nos novamente acima da curva da média dos valores atingidos entre o período de 2003 e 2021. Este gráfico presente na Figura 6, representa as emissões acumuladas de dióxido de carbono (CO₂) durante os anos mencionados anteriormente. Estas emissões são medidas através de Mt, isto é, toneladas métricas de dióxido de carbono, MTCO₂, que representam a soma de todas as emissões de CO₂ que foram produzidas através das emissões provenientes da indústria do cimento e a partir de combustíveis fósseis.

Através da presença da Figura 6 e de sua respetiva análise, conseguimos ainda constatar que o valor máximo acumulado das emissões destes gases atingiu no final de cada ano do período em análise (2021-2023) uma média de 20 MTCO₂, enquanto em 2022, na União Europeia, já se atingiu e ultrapassou o valor anterior, apresentando já em Setembro 25 MTCO₂, ou seja, quando falta ainda um trimestre para o final do ano, no qual indubitavelmente essas emissões irão aumentar o valor acumulado.

Considerando estas circunstâncias, facilmente se poderá concluir que no presente ano houve um agravamento dos valores da emissão de dióxido de carbono relativamente aos anos anteriores.

1.2 Problema

Os incêndios são um problema cada vez mais recorrente e constituem uma verdadeira ameaça, quer ambiental, quer económica. Assim, a sua rápida deteção torna-se crucial para a sua extinção, de modo a evitar danos e, por isso, a criação de instrumentos que permitam combatê-los a priori é fundamental.

O *Ciclope* é um sistema com muita experiência na monitorização de incêndios florestais, servindo-se de câmaras de vídeo, para realizar um controlo diurno e noturno, com bons resultados em praticamente todas as condições meteorológicas. Apresenta condições para funcionar em qualquer local, já que é autónomo no que concerne ao fornecimento de energia e comunicações. Apresenta outras funcionalidades, como o fornecimento de dados meteorológicos, a localização de viaturas e pessoas e sistemas de deteção automática. Assim, para além de monitorizar grandes extensões a um preço reduzido, permite a deteção de incêndios de forma automática para que a resposta seja instantânea, assegurando uma gestão mais eficiente de recursos no combate a este flagelo [11].

Com este trabalho, pretende-se o desenvolvimento de um algoritmo, com base em aprendizagem automática, *Deep Learning* e processamento de imagem, que consiga detetar incêndios com exatidão, recorrendo a fotos, e ultrapassar determinadas dificuldades encontradas durante o processamento de imagem, como o mau alinhamento e a ocorrência de nevoeiro.

1.3 Objetivos

O objetivo deste trabalho é o de desenvolver um sistema de classificação que, recebendo imagem e consiga identificar automaticamente e com precisão a presença de incêndios.

Para além disso, espera-se conseguir ultrapassar dificuldades encontradas que sejam inerentes ao processo de reconhecimento de imagens, como a ocorrência de nevoeiro e mau alinhamento daquelas. Este sistema será desenvolvido tendo como recurso a aprendizagem automática *Deep Learning* e processamento de imagem.

2 Estado de Arte

A detecção de objetos faz parte de um dos campos da *computer vision*, cuja especialidade é a identificação e classificação de objetos. O objetivo desta dissertação será o desenvolvimento de uma rede neuronal convolucional (*CNN*), que terá como propósito identificar automaticamente a presença de fogo numa imagem. Deste modo, serão expostas as diversas técnicas e tecnologias relevantes para o processo e que se encontram diretamente relacionadas com os tópicos envolvidos no contexto do problema atual.

2.1 Machine Learning

O *Machine Learning* é um subcampo da inteligência artificial que tem como intuito fornecer aos computadores a capacidade de fazer previsões sem que isso esteja explicitamente programado.

Machine learning é o desenvolvimento de métodos que podem melhorar automaticamente através do treino deste modelo, fornecendo ao mesmo um *dataset*, com o propósito de melhorar o algoritmo, e outro *dataset* diferente, de testes. Os dados de treino são utilizados para treinar o modelo a prever o resultado correto.

Os sistemas baseados em *machine learning* podem ser em grande parte classificados em três principais categorias, de acordo com o tipo de dados que foram utilizados pelo sistema [34].

2.1.1 Aprendizagem supervisionada

Este tipo de aprendizagem requer a utilização de um *dataset* para realizar uma previsão sobre os dados fornecidos, classificados; este sistema usa os dados que recebe de *input*, para aprender a identificar e classificar corretamente o objeto de estudo. O sistema recebe dados e com estes aprende a reconhecer o objeto em questão, aprendendo através de padrões e semelhanças entre as diversas imagens presente no *dataset* [34].

2.1.2 Aprendizagem supervisionada

Os algoritmos que seguem esta abordagem consomem um conjunto de dados, guardados num *dataset* de treino, com o objetivo de aprender com os mesmos; o algoritmo aprende com os dados, não rotulados, identificando semelhanças entre os dados ou ausências destas [34].

2.1.3 Aprendizagem de reforço

O objetivo dos algoritmos de aprendizagem por reforço é maximizar a recompensa total e diminuir as penalizações; este modelo aprende através da experimentação e do erro, durante a execução de várias tarefas com o intuito da realização do objetivo.

Para além destes três tipos de aprendizagem referidas, ainda existem outras categorias. Estas surgem através da combinação destas categorias referenciadas [34].

2.2 Deep Learning

Deep Learning é uma subárea do campo *machine-learning* que se dedica a algoritmos inspirados em redes neurais.

As redes neuronais tentam simular o comportamento do cérebro humano, aprendendo com grandes quantidades de dados.

Os algoritmos de *Deep Learning* são capazes de compreender representações complexas a partir dos dados fornecidos, tal como são recebidos. Estes é uma abordagem de aprendizagem na qual o algoritmo se baseia e aprende com os dados fornecidos.

Este tipo de algoritmo teve um grande êxito devido a sua precisão, vindo a ser utilizado em deteção de imagens e reconhecimentos das mesmas. Em 2014, foi criado um algoritmo um de reconhecimento facial, que produziu resultados mais precisos dos participantes presentes nesta experiência [1]. O *Deep Learning* teve um impacto positivo nas nossas vidas, tendo como tarefa a melhoria de muitos serviços recorrendo à automatização, sem a necessidade de uma intervenção manual.

O primeiro algoritmo de *Deep Learning* foi publicado por Alexey Ivakhnenko e Lapa em 1967 [2]. Entretanto, o trabalho levado a cabo por por Kunihiko Fukushima em 1980 serviu de inspiração para o desenvolvimento de outros projetos relacionados com o *computer vision* [3].

Yann LeCun criou, em 1989, um algoritmo, cuja intenção é a identificação de códigos ZIP escritos manualmente. Para a obtenção deste resultado, foi necessário o treino do algoritmo, cujo processo demorou três dias [4].

Seis anos mais tarde, em 1995, este processo de treino foi otimizado, [5], tendo desenvolvido uma rede contendo seis camadas totalmente ligadas. A velocidade do algoritmo é traduzida por uma equação complexa que envolve vários fatores que podem influenciá-la, incluindo o problema do *vanishing gradient* analisado em 1991 por Sepp Hochreiter [6].

Em 2009, a empresa Nvidia tornou-se pioneira no ramo ao desenvolver redes neurais que tinham sido treinadas usando as *GPUs*, *Graphics Processing Unit*, do computador, unidade de processamento gráfica, ou como conhecemos, placa gráfica. Esta mudança permitiria diminuir os tempos de execução em larga escala, sendo possível reduzir o que seriam semanas intensivas de treinos para uma questão de dias. Este processo, possibilita, portanto, o uso das *GPUs* para o treino do algoritmo, acelerando o treino, visto que as placas gráficas são a melhor escolha para os cálculos vetoriais envolvidos neste processo [7].

Finalmente, em 2012, Ciresan demonstrou como seria possível obter drasticamente melhores resultados, propondo a utilização de camadas de *max-pooling*, que consistem em reduzir as dimensões dos dados atuais. Este processo consiste em diminuir e eliminar pixels com valores mais baixos [8].

2.3 Convolutional Neural Network

As *CNNs* são um tipo de rede neuronal particularmente adequada para tarefas de classificação de imagem e *computer vision*. Têm sido responsáveis por alguns dos resultados mais impressionantes em AI nos últimos anos, tais como a identificação de objetos em imagens com precisão quase humana.

As redes convolucionais funcionam através da convolução de uma imagem de entrada com um conjunto de filtros de aprendizagem. Estes filtros são capazes de extrair *feature-map*

de baixo nível da imagem, tais como arestas e cantos. A saída da convolução é então alimentada por uma série de camadas, onde são extraídas características mais complexas. Finalmente, estas características são utilizadas para classificar a imagem.

As CNNs são poderosos processos de processamento de imagem, inteligência artificial (IA) que utilizam *deep learning*.

As CNNs revolucionaram a visão por computador e tornaram-se o método mais avançado para muitas tarefas. No entanto, possuem as suas limitações. Um dos principais desafios na formação das CNNs é a grande quantidade de dados necessários, uma vez que as redes convolucionais precisam de ver muitos exemplos de um objeto para aprenderem a reconhecê-lo. Outro desafio prende-se com o facto de as redes convolucionais serem frequentemente muito profundas, o que significa que têm um grande número de camadas. Estes factos podem condicionar o seu treino, tornando-o muito moroso e difícil.

2.3.1 Arquitetura

Uma rede neuronal convolucional é constituída por várias camadas, tais como: uma camada de entrada, uma camada de saída, camadas de ativação, camadas ocultas, que incluem camadas que executam operações de convolução com a matriz de entrada e uma *pooling layers*. À medida que realizamos a operação de convolução ao longo da matriz de entrada da camada, este procedimento produz um *feature-map*. Este foi obtido devido à aplicação da operação de convolução do filtro desejado em relação à matriz de entrada original. O resultado deste procedimento, *feature-map*, alimenta a camada seguinte, contribuindo para a entrada da mesma. Posteriormente, este *feature-map* obtido anteriormente, passa por um processo de *pooling*, que tem como intuito reduzir as dimensões dos dados atuais. Este processo consiste em diminuir e eliminar pixels com valores mais baixos, processo se encontra presente na Figura 7.




Figura 7 - Processo de max-pooling [24]

Nas camadas nas quais são produzidos os *features-maps*, cada uma recebe a saída da sua camada imediatamente anterior como sua entrada e passa a sua saída como entrada para a camada seguinte. Geralmente, estes sistemas costumam ter entre duas a quatro camadas de convolução [19].

2.3.1.1 Camada de Ativação

Nas camadas de ativação, é aplicado um processo denominado de *RELU (Rectified Linear Unit)*, que serve para colocar os valores negativos a zero, eliminando dados que não iriam ser necessários para o cálculo dos algoritmos [18].

Um exemplo desta função de ativação não linear pode ser evidenciado no exemplo da Figura 8.




Figura 8 - Processo RELU [17]




Figura 9 - Gráfico da função matemática que exprime o RELU [18]

A função *RELU*, define-se seguindo a seguinte equação:

$$\text{RELU} = \max(0, X) \quad (1)$$

O Figura 9 contém o gráfico matemático relacionado com a equação do *RELU*.

Este processo ajuda a prevenir o crescimento exponencial do cálculo que iria ser necessário que o algoritmo efetuasse no momento da classificação do mesmo. Para além disso, este processo permite ultrapassar o problema do *vanishing* ou *exploding gradient*.

2.3.1.2 Camada de Classificação

O sistema encontra-se montado de tal forma que a saída de uma camada atua como o valor para entrada da camada seguinte. Durante a fase de treino, os pesos de todos os neurónios são atualizados. Estes pesos modelam as características representativas dos dados de treino de entrada e, por sua vez, podem realizar a classificação tão esperada. Esta é a camada totalmente ligada que calcula o peso de cada classe a partir dos *features-maps* de uma camada nas etapas anteriores. Os *feature-maps* da camada final são passados para as camadas totalmente conectadas. As camadas neuronais totalmente ligadas são utilizadas como uma camada de classificação. *Soft-max* é usado para fornecer as probabilidades de cada classe respetiva, a distribuição de probabilidade para ambas as classes [35].

2.4 Estado da Arte de Sistemas de Reconhecimento

Neste subcapítulo, serão descritos vários sistemas de classificação de objeto, com recursos de imagens, assim como outras informações diretamente relacionadas com este tema. Deste modo, irão ser apresentados alguns modelos de *Machine Learning* que são usados em *computer vision* e reconhecimento/deteção de objetos.

2.4.1 R-CNN

Em 2014, Girshick desenvolveu o *R-CNN* (*Region-based Convolutional Neural Networks*) que tinha como objetivo detetar objetos em qualquer imagem, fornecida como *input*, definindo limites à sua volta [10].

Girshick propôs este modelo que tem como tarefa inicial propor as regiões de interesse que a imagem possa ter, independentemente das categorias. Este realiza uma pesquisa seletiva para extrair 2000 regiões de interesse da imagem fornecida, *ROI* (*Region of Interest*). Depois de obter os *ROI*'s, estes são consumidos pela rede neuronal para produzir os *features*. Acabando o processo, posteriormente, um conjunto de *SVM*'s (*Support Vector Machine*) irá proceder à classificação de cada região anteriormente obtida.

O processo com o qual o R-CNN funciona, encontra-se demonstrado na Figura 10, que retrata o método como funciona, começando pela extração de regiões, ROI, e seguidamente prosseguindo para a classificação das mesmas regiões de interesse.

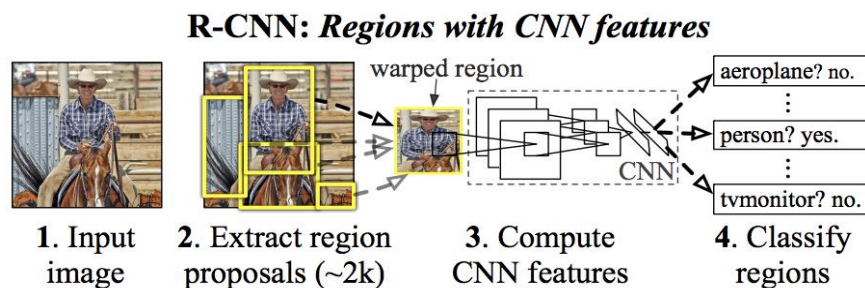


Figura 10 - Funcionamento do R-CNN [22]

2.4.1.1 Problemas Associados com o R-CNN

- É necessário muito tempo para treinar a rede, visto ser preciso classificar cerca de 2000 regiões por cada imagem recebida.
- Não será uma boa opção para ser implementado como sistema de deteção em tempo real, uma vez que o tempo de execução deste modelo é o seu maior constrangimento.

2.4.2 Fast R-CNN

Em comparação com o modelo descrito anteriormente, existe uma pequena diferença, tendo em conta que, em vez de a rede neuronal consumir as regiões de interesse propostas, esta irá consumir e usar a imagem de entrada para gerar um *feature-map*.

Seguidamente, procede-se à identificação das regiões propostas. Estas regiões, *ROI*, passam pela *pooling layer*. Esta camada tem como objetivo a identificação das regiões de interesse e estas vão sofrer um processo de *max-pooling* de forma que as regiões possuam todos o mesmo tamanho. Estas vão ser agrupadas num vetor de características de *ROI* para que possam ser consumidas por uma camada totalmente ligada, Figura 11.

Com isto, podemos concluir que o *Fast-RCNN* é mais rápido que o *R-CNN* porque não é necessário produzir e analisar 2000 regiões por imagem para a rede neuronal. Para além disso, é possível analisar múltiplas regiões de interesse ao mesmo tempo [22].

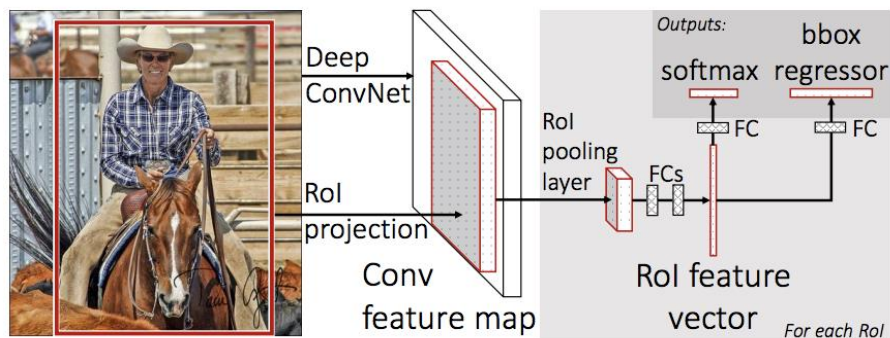


Figura 11 - Funcionamento do Fast R-CNN [22]

2.4.3 Faster R-CNN

Este modelo foi desenvolvido tendo como inspiração os que foram anteriormente referidos, visto que o *Faster R-CNN* aproveita a utilização de uma rede neuronal convolucional e um mecanismo de deteção *FAST R-CNN*.

Neste modelo, obtemos inicialmente os *feature-map*, após realizar a operação de convolução do filtro na matriz do *input* original.

Depois o processo passa pelo *RPN*, *region proposal network*, no qual o mapa final anteriormente obtido vai ser utilizado para prever e estimar a probabilidade de o objeto estar naquela região ou não [15], como demonstra o exemplo presente na Figura 12.




Figura 12 - Funcionamento do Faster R-CNN [22]

Devido ao facto de o Faster-RCNN fazer partido do uso de *Region Proposal Network*, existem várias vantagens adjacentes associadas ao uso do mesmo, tais como por exemplo: as regiões propostas são agora geradas utilizando uma rede que poderia ser treinada, de acordo com a tarefa de deteção específica [22].

Para além disso, produz melhores resultados que dependem de pesquisa seletiva. Finalmente, visto que a imagem processada utiliza as mesmas camadas usadas na rede convolutiva, o *RPN*, *Region Proposal Network*, não desperdiça tempo a produzir os resultados em comparação a outros algoritmos que usam pesquisa seletiva.

2.4.4 YOLO




Figura 13 - Yolo Detector [13]

2.4.4.1 Yolo v1

Como a Figura 13 demonstra através da divisão e identificação de cada objeto presente na figura observada, o *Yolo* divide a imagem em vários segmentos, criando *boundary boxes* com o intuito de dividir para conquistar e uma matriz com dimensões $Z \times Z$. Prevendo o reconhecimento do objeto através de uma única observação da imagem, como o nome indica, *You Only Look Once* [11]. As *boundary boxes* são definidas pelos seguintes atributos: C_x , C_y , B_w , B_h e, por fim, p .

C_x e C_y representam o centro da *boundary box* em questão, B_w e B_h definem as dimensões da *boundary box*, sendo B_w a largura e B_h o comprimento, e p representa a probabilidade correspondente do objeto/classe.

Este algoritmo permite uma maior taxa de *frames* por segundos para cenários de reconhecimento implementados em tempo real [13].

Para além disso, o *Darknet19* [13], é utilizado no *YOLO V2*, apresentando uma grande rapidez no reconhecimento e identificação de objetos, sendo esta qualidade crucial para tarefas de previsão em tempo real.

2.4.4.3 Yolo v3

A mais recente versão deste algoritmo, apresenta a utilização do *Darknet-53* ao invés do anteriormente usado, *Darknet-19* [14]. Anteriormente, eram usadas camadas *soft-max*, contudo, isto mudou na terceira versão do algoritmo *YOLO*, pois o *soft-max* foi concebido para ser usado com múltiplas classes que sejam mutuamente exclusivas.

Por exemplo, se tivermos o caso no qual possuímos classes como ANIMAL e ELEFANTE, o algoritmo falhará para este caso. Com base neste facto, os autores deste algoritmo fazem a previsão usando regressão logística [21].

2.5 Desafios encontrados na deteção de objetos

No âmbito desta secção, irão ser identificadas alguns dos problemas associados a área de *computer vision*, no âmbito da deteção de objetos.

2.5.1 Overfitting

É um problema que acontece quando o modelo generaliza o objeto em questão, revelando um bom desempenho com os dados atuais fornecidos, pois este algoritmo memoriza os padrões dos dados, acabando por não ser possível atingir o objetivo inicial.

O elevado desempenho do modelo na fase de teste é um indicador deste problema. O problema pode surgir devido ao facto de o tempo de treino ser demasiado longo, permitindo ao sistema aprender a reconhecer padrões, ou do facto de o modelo poder ser demasiado complexo. Daí que, para ultrapassar este problema, se use *droup-out layers*. Geralmente, a *drop-out layer* é utilizada posteriormente à *pooling layer* [16].

A *drop-out layer* modifica aleatoriamente os valores de entrada para 0. Os valores que não foram modificados são multiplicados por $1/(1 - \text{taxa})$, sendo esta taxa a frequência fornecida a cada etapa da fase de treinos [19].




Figura 15 - Loss e Accuracy em situação de Overfitting [26]

Um modelo encontra-se em situação de underfitting quando este não só possui um erro de treino elevado, mas também quando possui erro de validação bastante elevado. Por outro lado, uma situação de overfitting ocorre quando o modelo apresenta um erro de treino baixo, contudo, apresenta um erro de teste elevado.

Na situação de overfitting, como referi anteriormente, o que acontece é a incapacidade do modelo de generalizar o caso através dos objetos de estudo/exemplos recebido na etapa de treino [26].

2.5.2 Class Imbalance

Este problema acontece quando uma das classes que pretendemos identificar contém menos amostras da mesma no *dataset*, quando a distribuição das proporções entre ambos os casos é desproporcional, tendo por consequência o favorecimento do sistema em favor do objeto de estudo fornecido em maioria.

Em jeito de conclusão, devido ao facto de os dados se encontrarem desproporcionais para ambos os casos, o algoritmo irá possuir uma menor precisão para o objeto que possui menos dados apresentados [20].

2.5.3 Exploding Gradient e Vanishing Gradient

Pode acontecer quando os pesos iniciais do sistema sofreram *loss*. Os gradientes acumulados vão ser alterados e atualizados com valores que podem levar a uma rede instável. No caso de *exploding gradiente*, esta alteração pode tornar os valores tão altos, tornando-se um peso, podendo levar o sistema a uma paragem, enquanto no caso dos *vanishing gradients*, estas alterações podem ser tão insignificantes que podem prevenir a aprendizagem [36].

Exploding Gradient pode ser reconhecido quando o modelo não possui uma *performance* positiva na fase de treino, o modelo tem grandes alterações na *loss*, sendo a mesma variável e os pesos crescem exponencialmente [36].

No caso do *Vanishing Gradient*, o modelo evolui muito lentamente, durante a fase de treino, chegando a parar o seu progresso, e os seus pesos vão diminuindo o seu valor, até chegar a possuir valor nulo durante a fase de treino [36].

2.6 Soluções existentes

Existe uma solução desenvolvida pela Forest Fire Finder (FFF), que foi adquirido pela Autoridade Nacional de Proteção Civil (ANPC) que utilizada detetores e sensores óticos.

Contudo, “Entre Julho e Dezembro de 2013, o FFF emitiu 310 falsos alarmes e 204 alarmes verdadeiros. De Janeiro a Agosto deste ano, o sistema disparou 24 alarmes verdadeiros e 1013 alarmes falsos, ou seja, 2,3% dos alertas indicavam incêndios florestais.” [43]

Também existe projeto português denominado por FireAI – Intelligent Forest Fire Detection Solution, que foi desenvolvido pela empresa Bee2fire. Este produto consiste num sistema de deteção de incêndios florestais.

Este sistema “opera 24x7 como um sistema de vigilância, deteta automaticamente incêndios em estágios iniciais em distâncias de até 15km / 9,3mi e auxilia nos processos de tomada de decisão, permitindo uma resposta rápida e suporte nos esforços de operação de combate a incêndios” [44].

3 Análise de Valor

O principal objetivo da análise de valor é avaliar o modo a partir do qual seria possível aumentar o valor de um artigo/serviço, sem diminuir a qualidade prestada do mesmo.

Trata-se de um processo sistemático, que requer bastante planeamento, coordenação e avaliação. Deste modo, pode-se concluir que a análise de valor é um processo sistemático, formal e organizado de análise e avaliação. O propósito da análise de valor é a avaliação das exigências sentidas pelo cliente e, para o seu objetivo ser alcançado, o processo de análise de requisitos, que conduz a uma compreensão das funcionalidades e da definição do produto, sem ambiguidade, é, por isso, uma etapa crucial para o seu desenvolvimento. O valor inerente a um projeto é o produto duma equação complexa composta por muitos fatores, tais como: necessidade, desejo, interesse, crenças, atitudes e preferências.

Em suma, para concretizar o fornecimento de algo de valor ao cliente, devem ser cumpridos escrupulosamente os requisitos funcionais do produto, sendo que o processo deve permitir elevar o valor do mesmo, sem comprometer a sua qualidade.

3.1 Identificação da oportunidade

Os incêndios constituem uma ameaça. Estes afetam a sustentabilidade da fauna e dos ecossistemas que dela dependem, tendo como consequência o desequilíbrio, como anteriormente referido, quer ambiental, quer económico. Os incêndios têm um impacto negativo a vários níveis, tais como: o empobrecimento das condições edáficas, perda de biodiversidade, possíveis deslizamentos de terra, destruição de *habitats*, destruição de ecossistemas que necessitam de equilíbrio, impacto na economia e turismo na região incidente, emissões de dióxido de carbono, poluição da água e erosão do solo.

Para além disto, os danos são irreversíveis, pois, ainda que ocorra a reflorestação da área ardida, esta será efetuada sem uma reposição das espécies vegetais e animais autóctones.

Um incêndio rural é um incêndio florestal ou agrícola que decorre num espaço rural. Este difere dos outros devido à velocidade com que alastra, desde o lugar onde teve origem e ao grau de imprevisibilidade que possui, visto que pode mudar de direção arbitrariamente.

O termo “incêndio agrícola” deriva do facto de o incêndio rural ter uma área agrícola ardida superior à área ardida florestal e em que a mesma seja inferior a um hectare, enquanto, no caso dos incêndios florestais, a área florestal que foi devastada é superior à área agrícola, tendo este incêndio afetado uma área superior a um hectare de área florestal ardida.

Com base no Livro Branco dos Incêndios Florestais Ocorridos no verão de 2003, providenciado pelo governo em cooperação com a Direcção-Geral das Florestas, e com os devidos dados presentes na Tabela 5, podemos comprovar que, em 2003, durante o período entre 1 de janeiro e 30 de Setembro, a área ardida corresponde a 390.146 hectares, tendo ocorrido 4279 incêndios florestais [25].

Tabela 5 - Distribuição mensal dos incêndios [25]

Mês	Número de ocorrências		Reacendimentos	Área ardida (ha)		
	Incêndios Florestais	Fogachos		Povoamentos	Matos	Total
Janeiro	22	70	0	11	39	50
Fevereiro	30	91	0	14	48	62
Março	188	490	9	276	597	872
Abril	120	415	0	246	320	566
Maio	286	1.208	48	1.157	556	1.713
Junho	581	2.334	144	7.232	4.026	11.258
Julho	759	2.552	153	55.863	21.353	77.216
Agosto	1.473	4.630	475	191.433	94.644	286.077
Setembro	820	2.304	0	6.679	5.654	12.333
Total	4.279	14.092	913	262.909	127.237	390.146

Relativamente à distribuição mensal dos incêndios, conseguimos comprovar a existência de uma maior concentração da ocorrência de incêndios durante o mês de Agosto, tendo perto de quase o dobro do que nos outros meses.

Além disso, é possível verificar que embora em Setembro tenha havido maior ocorrência de incêndios florestais, a área florestal afetada pelos incêndios é menor quando comparado com Junho e Julho.

Tabela 6 - Distribuição anual dos incêndios e comparação da área ardida [25]

Anos	Número de ocorrências		Área ardida (ha)		
	Incêndios Florestais	Fogachos	Povoamentos	Matos	Total
1998	8.239	25.842	57.203	99.813	157.016
1999	5.532	18.827	30.940	39.035	69.975
2000	8.016	23.755	67.318	86.487	153.805
2001	6.018	17.439	42.986	63.345	106.331
2002	6.473	19.887	65.092	59.215	124.308
2003*	4.279	14.092	262.909	127.237	390.146
Média 1998-2002	7.061	19.936	43.447	60.669	104.116
Desvio	-39,4%	-29,3%	+605%	+210%	+375%

Com base na análise da Tabela 6, conseguimos comprovar a existência de um menor número de ocorrências em relação aos últimos 5 anos, relativamente ao ano de 2003.

Contudo, a área ardida é muito superior em comparação aos anos anteriores. Se compararmos os valores de 2003 com os valores medianos entre 1998 e 2002, comprova-se que a área ardida devastada em povoamentos florestais é quase 6 vezes maior. Em relação à área ardida em matos, esta representa um acréscimo de 210%, sendo estes dois dados juntos, em relação à área ardida total verificou-se um acréscimo de 375% [25].

Na Tabela 7, apresenta-se uma tabela com as diferentes causas de incêndios relativamente ao período compreendido entre 2011 e 2021.

Tabela 7 - Causas dos incêndios [25]

Causas indeterminadas	39
Incendiarismo	28
Trovoada	25
Sob investigação	22
Vandalismo	13
Renovação de pastagens	12
Linha elétrica	5
Máquinas e equipamentos	5
Conflitos de caça	4
Fumadores	4
Caminhos-de-ferro	3
Incêndios não investigados	3
Máquinas agrícolas	2
Queimada	2
Lançamento de foguetes	2
Limpeza do solo florestal	1
Confeção de comida	1
Acidente de viação	1
Chaminés	1
Danos provenientes da vida selvagem	1
Apicultura	1

Analisando a Tabela 7, conseguimos perceber que a grande parte dos incêndios teve como causa a trovoada, sendo que estes incêndios causados pela mesma apresentam uma dimensão que representa 14,30% dos incêndios totais.

Para além disso, também podemos verificar que 16% dos incêndios de 2002 em Portugal tiveram como causa o incendiarismo, sendo que 7% aconteceram devido a “práticas de vandalismo”, e que 4% ocorreram devido aos reacendimentos de incêndios anteriores, que não chegaram a extinguir-se totalmente e alastraram novamente. Estão a ser investigados 12,5% e 22,3% foram provocados por causas indeterminadas [25].

3.2 Análise da Oportunidade

Existem várias formas de deteção de incêndios e de reportar os mesmos, como por exemplo: os sapadores florestais, os postos de vigia, a vigilância aérea e móvel motorizada, composta por pequenas equipas, e a vigilância através de câmaras térmicas.

Os sapadores florestais são equipas constituídas por entidades detentoras ou gestoras de espaços florestais, que têm como função a defesa das florestas e a prevenção dos incêndios florestais. Enquanto equipas especializadas, com formação específica, fazem o acompanhamento de fogos controlados, efetuam queimadas e ações de controlo e eliminação de agentes bióticos.

Os postos de vigia constituem um dos meios clássicos de vigilância e deteção deste flagelo e estão espalhados pelo país. Os intervenientes têm a função de alertar os serviços locais, nomeadamente de Proteção Civil, os Sapadores Florestais e os bombeiros, para ser feito o combate ao incêndio de forma mais célere possível e, preferentemente, numa fase inicial do mesmo[24]. A vigilância motorizada é constituída por pequenas equipas com equipamento próprio, nomeadamente meio de transporte. No entanto, devido à redução do investimento neste programa e ao facto de as estruturas locais serem manifestamente incapazes de fiscalizá-lo, optou-se pelo reforço dos outros meios de prevenção e abandono da atuação desta modalidade no período noturno.

O sistema de vigilância aérea é assegurado por aeroclubes, através de um protocolo.

A componente da videovigilância é um dos sistemas atuais implementados em Portugal ou em fase de implementação e conta com o envolvimento dos comandos distritais de socorro (CDOS), a GNR, Proteção Civil e o Instituto de Conservação da Natureza e Floresta.

Não obstante o investimento nestas modalidades de deteção de incêndios, que muitas vezes, depende das autarquias envolvidas e de empresas da área, é evidente que estas nem sempre se revelam eficazes.

Assim, propõe-se o desenvolvimento de um sistema automático, autónomo e instantâneo de incêndios, que, conjugado com as câmaras térmicas, permitiria a deteção mais precisa e rápida de um incêndio, para além de resultar numa economia de meios humanos e económicos.

3.3 Fast

3.3.1 Definição

A técnica *FAST* auxilia na tarefa de reflexão sobre o problema, contribuindo significativamente para a identificação do âmbito do projeto. Esta tem como tarefa ilustrar o modo como a solução proposta será realizada, desenvolvendo o que será um protótipo do modo como o sistema atua.

A forma como a informação é disponibilizada num diagrama FAST permite aos participantes identificar todos os requisitos necessários, fazendo perceber o problema sem ambiguidade.

3.3.2 Benefícios

Como referido anteriormente, uma das mais valias do FAST é o facto de transmitir a forma como o processo é realizado, promovendo o pensamento e discussão do assunto e possíveis formas de o realizar [37].

Para além disso, também tem outras vantagens como as seguintes:

- é uma ferramenta útil na identificação dos requisitos
- ajuda a definir e clarificar o problema.
- promove uma compreensão melhor sobre o sistema

3.3.3 Diagrama

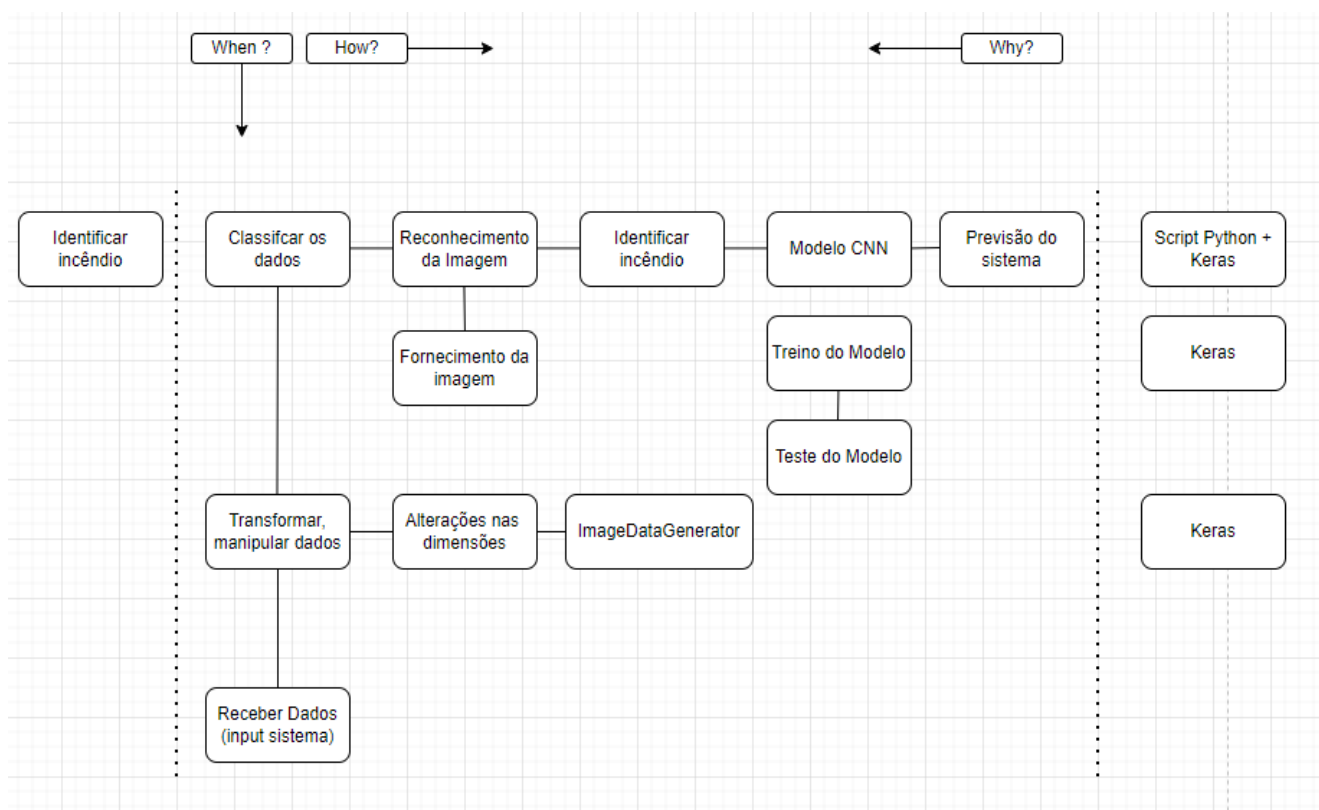


Figura 16 - Diagrama FAST

Através do diagrama de Fast presente na figura 16, é explicado a forma como o processo é executado desde o início até ao fim do ciclo.

Para o desenvolvimento deste produto, foi necessário reunir um conjunto de diversas imagens para treinar o modelo *CNN*. Estas imagens foram escolhidas com cuidado, tentando cobrir todos os exemplos mais realistas possíveis de modo a tentar fornecer um resultado fidedigno. Para tal foi necessário catalogar as imagens em diferentes categorias inicialmente como fogo e não fogo, e mais especificamente imagens com fumo de incêndio para o mesmo aprender. Também foram adicionados exemplos de imagens com nevoeiro e pôr do sol para tentar contrariar e ensinar para que estes não sejam confundidos com fumos ou incêndios, devido às suas semelhanças. Estas imagens possuíam diferentes tamanhos que, para efeitos de teste, foram normalizadas fazendo uso do *ImageDataGenerator*.

Posteriormente, depois de ter as imagens totalmente prontas, processadas e devidamente catalogadas, estas vão ser usadas para treinar o modelo em várias iterações.

Após este último passo, este conjunto de imagens devidamente catalogado, irá ser alimentado ao sistema para que este possa aprender, passando por várias iterações e fases de treino, com perspetiva, de se., tudo correr bem, que melhore a cada iteração.

Após este sistema e modelo se encontrar totalmente configurado e com os devidos pesos definidos, será apenas necessário o fornecimento de imagens de modo a verificar a presença ou não de fogo nas mesmas. O sistema responderá com uma previsão para o contexto atual.

4 Experimentação e Avaliação

Este capítulo da dissertação tem como finalidade demonstrar o modo como o modelo desenvolvido neste projeto vai ser avaliado. Inicialmente, serão não só definidos os parâmetros através dos quais o sistema vai ser avaliado, como também serão apresentadas as métricas.

4.1 Objetivo

Como anteriormente referenciado na Introdução, o objetivo desta dissertação é a criação de um algoritmo que permita reconhecer automaticamente a presença de fogo numa imagem fornecida ao sistema, ultrapassando diversos problemas existentes, tanto na área em que este trabalho se insere, reconhecimento de imagem, como no contexto de um incêndio, pois o fumo e nevoeiro dificultam a tarefa de reconhecimento.

4.2 Metodologia de Avaliação

O método de avaliação vai ser definido com base nos valores dos indicadores de avaliação, sendo estes a duração do tempo de treino, *loss* e a precisão do modelo na identificação do objeto.

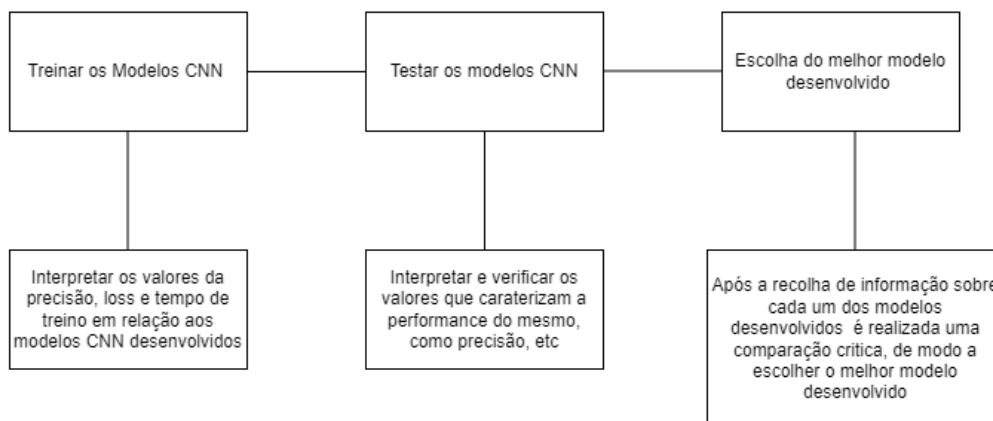


Figura 17 - Diagrama da Metodologia

Inicialmente, após o modelo *CNN* ser desenvolvido, este irá ser treinado com um *dataset* de dados de treino, consumindo diferentes tipos de imagens, com e sem a presença de fogo. Posteriormente, o mesmo irá ser testado com uma *dataset* de teste que irão avaliar a precisão, *loss* e tempo de treino.

Com base nestes valores e a interpretação dos diversos modelos desenvolvidos, será selecionado um dos modelos desenvolvidos com o *dataset* extraído manualmente por mim.

4.3 Requisitos

Relativamente a requisitos necessários para montar este sistema, o mais importante, sem via de dúvida, é o *dataset*. Não só em si a sua existência, mas a forma como este foi montado e estruturado. Para que este *dataset* exista, é necessário inicialmente proceder à realização da catalogação e divisão das imagens em seus diversos tipos, as imagens precisam de ser todas caracterizadas e catalogadas. Para além disto, as imagens que constituem o *dataset* que irá ser usado posteriormente pelo sistema, precisam de estar todas com as mesmas dimensões, pelo que, estas imagens foram todas normalizadas através do uso do método *ImageDataGenerator* proveniente da biblioteca *Keras*.

Uma das dificuldades encontradas durante o desenvolvimento da tese, foi definitivamente, o facto de se ter de recorrer à escolha e extração manual de imagens, devido ao facto de não me ter sido fornecido o *dataset* pela equipa do Ciclope. Este acontecimento limitou os resultados do modelo não só a nível de precisão, mas também a nível de realismo, pois com este o *dataset* usado para treinar o modelo seria muito mais rico e teria cenários realísticos onde este seria usado.

4.4 Dataset

Neste subcapítulo é apresentado a forma como o *dataset* foi constituído e catalogado.

Tabela 8 - Configuração (Treino - NoFire)

Cenário - NoFire	Treino
Nevoeiro/Nuvens	132
Outros (Flares, etc)	6
Por do sol	94
Floresta Normal	1059
Total	1291

A tabela 8 clarifica como foi constituído o *dataset* relativamente à class NoFire, na etapa de treino. Esta contém exemplos de nevoeiro e nuvens, para ajudar a distinguir estes exemplos do fumo dos incêndios. Para além disso possui exemplos do pôr do sol e diversas florestas.

Tabela 9 - Configuração (Treino - Fire)

Cenário - Fire	Treino
Fumo	346
Incêndios-Fogo	1 932
Outros (tochas, fósforos, etc)	11
Total	2289

A tabela 9 contém os diversos exemplos que constituem a classe Fire, na fase de treino do modelo. Estes exemplos contêm cenários reais com presença de fogos com o objetivo de ajudar o modelo a reconhecer fogo e incêndios em diferentes ambientes.

Tabela 10 - Configuração (Validação - NoFire)

Cenário - NoFire	Validação
Nevoeiro/Nuvens	35
Por do sol	41
Floresta Normal	124
Total	200

Tabela 11 - Configuração (Validação - Fire)

Cenário - Fire	Validação
Fumo	187
Incêndios-Fogo	57
Total	244

As tabelas 10 e 11 possuem os mesmos exemplos que as tabelas anteriores, tabela 8 e 9, contudo estes dados são apenas usados para validação, para teste e não treino do modelo.

4.4.1 Exemplos das imagens do dataset

Este subcapítulo tem o intuito de demonstrar diversos exemplos sobre as diferentes categorias usadas na constituição do *dataset*. Deste modo, é possível verificar as diferentes categorias de imagens e exemplos usados no *dataset*.



Figura 18 - Exemplo de Floresta



Figura 19 - Exemplo de Nuvens



Figura 20 - Exemplo de Nevoeiro



Figura 21 - Exemplo de Fumo de Incêndio



Figura 22 - Exemplo de tochas



Figura 23 - Exemplo de Pôr de Sol



Figura 24 - Exemplo de Pôr de Sol

Inicialmente, o modelo foi constituído com recurso a exemplos de incêndios florestais e imagens de floresta, constituindo o ambiente natural onde as câmaras estariam normalmente colocadas, e diversos exemplos de diferentes perspetivas e ambientes nos quais havia incêndios, tendo por intuito distinguir a diferença entre a presença de fogo ou não.

Contudo, após verificar que existiam certos casos nos quais eram detetados falsos positivos, este foi modificado, adicionando outras imagens e casos para ajudar o sistema a contrariar este efeito.

Posteriormente, conforme dito anteriormente, verificou-se que, em certos casos, o sistema classificava erradamente a presença do pôr do sol, a presença de nuvens e, por fim, de nevoeiro. Devido a esse facto, o *dataset* sofreu uma alteração, pois foram adicionados novos e diversos exemplos, para que se tentasse contrariar este efeito. Assim, estes novos casos adicionados dizem respeito à existência de imagens relativas às três situações atrás referidas.

4.5 Configuração do modelo atual

Neste subcapítulo, vão ser apresentadas diversas informações sobre o modelo atual final. Estas informações fornecem algum contexto sobre a forma como o modelo foi criado e desenvolvido, assim como decorreu a sua fase de testes. Este modelo e os restantes, que irão ser mencionados futuramente, foram desenvolvidos através da biblioteca *Keras*. Estes modelos foram executados *no Google Collab* devido ao facto de estes serem hospedados em computador com uma maior carga computacional, sendo bastante mais rápido do que no próprio computador local.

4.5.1 Filtros do modelo

As *CNNs* resultam, da operação de convolução de um conjunto de filtros de aprendizagem aplicada ao longo da matriz de uma imagem de entrada. Estes filtros são responsáveis de extrair o resultado deste procedimento, os *feature-maps*. O resultado desta operação, *feature-map*, alimenta a camada seguinte, contribuindo para a mesma. Os filtros usados e responsáveis por contribuir na operação de convolução ao longo da matriz, foram obtidos pelo sistema durante e apos a realização de diversos treinos.

As *CNNs* utilizam filtros convolucionais que são treinados para extrair as os *feature-maps*, enquanto a última camada desta rede é a camada na qual a previsão é efetuada. Estes filtros são utilizados e aplicados às imagens passadas, para que, no final, seja possível fazer uma previsão sobre a imagem fornecida.

Os filtros presentes na Figura 25, são os filtros usados pelo modelo atual.




Figura 25 - Filtros do modelo atual

4.5.2 Treino do modelo

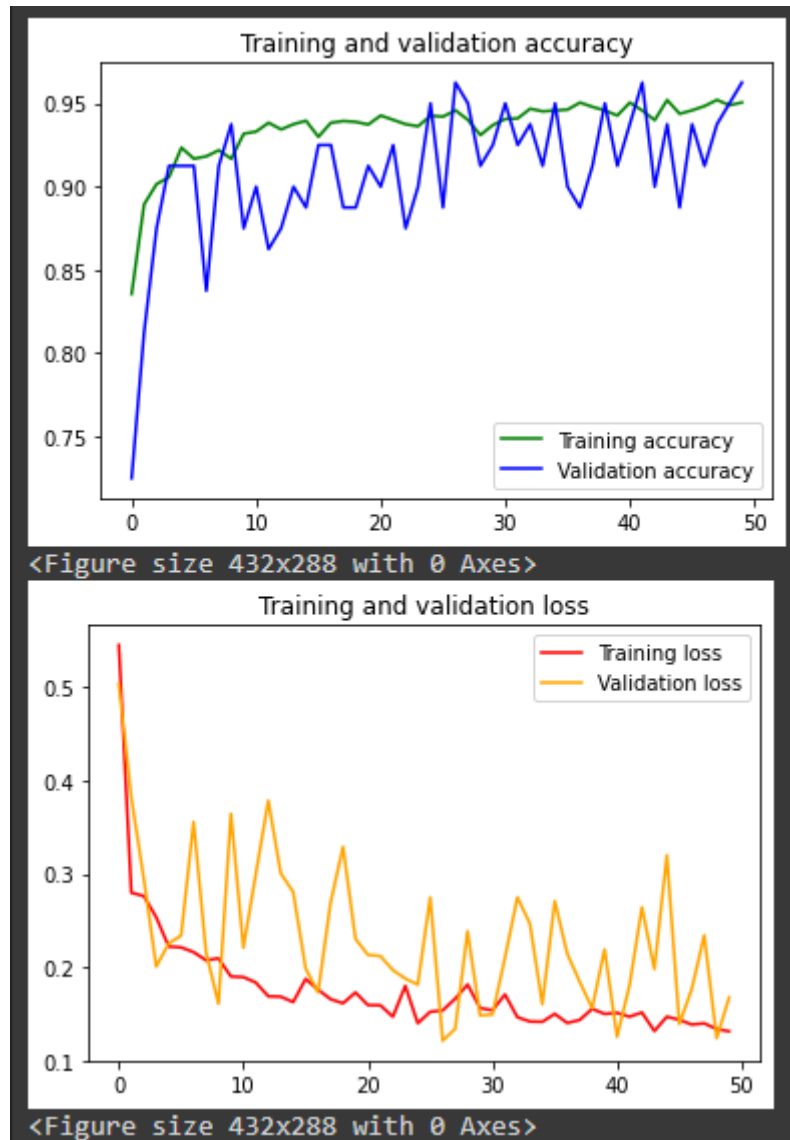


Figura 26 - Imagem do gráfico de treino do modelo

Este modelo foi desenvolvido tendo sido treinado em 50 *epochs* com 70 *steps_per_epoch*. Na Figura 26, é demonstrado um gráfico com a evolução do modelo durante estas diversas *epochs*, durante a fase de treino.

Através do conhecimento anteriormente enumerado no Estado de Arte em relação a *overfitting* e *underfitting* conseguimos concluir que o modelo não se encontra em nenhuma destas situações e que evolui normalmente como era esperado.

4.5.3 Arquitetura do modelo

Seguidamente, é apresentado um anexo que representa a estruturação e composição das diversas camadas de ativação e convolução do modelo atual. Este anexo é apresentado através da disponibilização da imagem através de um link do *Google OneDrive* devido à complexidade das redes adjacentes pertencentes a este sistema.

<https://drive.google.com/file/d/13loS5foEqwvTafX9VsJQysfRotCvhanW/view?usp=sharing>

O modelo é constituído por uma camada de *Input*, 94 camadas de convolução, 94 camadas de ativação, 94 camadas de *batch normalization*, 13 de *pooling*, 1 de *flatten*, 2 dense, 1 *dropout*, e 15 camadas *concatenate*, tendo no total 315 camadas.

4.6 Modelos Pré-treinados

Foram desenvolvidos vários modelos no intuito de chegar à solução, sendo alguns deles construídos utilizando modelos pré-treinados.

Os modelos pré-treinados, devido ao facto de terem sido treinados com dataset bastantes distribuídos e possuírem uma boa arquitetura, permitem alcançar melhores resultados de forma mais célere, com melhor performance e menos informação necessária. Para além disso, levaria bastante tempo para conseguir treinar estes modelos, que necessitam de uma elevada quantidade de dados.

Para efeitos de avaliação, para além do modelo desenvolvido no âmbito deste trabalho, também foram desenvolvidos outros vários modelos, que tiram partido destes modelos pré-treinados, como os seguintes: *InceptionV3* [39], *EfficientNet* [40], *ResNet50* [41] e *VGG-16* [42].

Model	Size	Top-1 Accuracy	Top-5 Accuracy	Parameters	Depth
Xception	88 MB	0.79	0.945	22,910,480	126
VGG16	528 MB	0.713	0.901	138,357,544	23
VGG19	549 MB	0.713	0.9	143,667,240	26
ResNet50	98 MB	0.749	0.921	25,636,712	-
ResNet101	171 MB	0.764	0.928	44,707,176	-
ResNet152	232 MB	0.766	0.931	60,419,944	-
ResNet50V2	98 MB	0.76	0.93	25,613,800	-
ResNet101V2	171 MB	0.772	0.938	44,675,560	-
ResNet152V2	232 MB	0.78	0.942	60,380,648	-
InceptionV3	92 MB	0.779	0.937	23,851,784	159
InceptionResNetV2	215 MB	0.803	0.953	55,873,736	572
MobileNet	16 MB	0.704	0.895	4,253,864	88
MobileNetV2	14 MB	0.713	0.901	3,538,984	88
DenseNet121	33 MB	0.75	0.923	8,062,504	121
DenseNet169	57 MB	0.762	0.932	14,307,880	169
DenseNet201	80 MB	0.773	0.936	20,242,984	201
NASNetMobile	23 MB	0.744	0.919	5,326,716	-
NASNetLarge	343 MB	0.825	0.96	88,949,818	-
EfficientNetB0	29 MB	0.771	0.933	5,330,571	-
EfficientNetB1	31 MB	0.791	0.944	7,856,239	-
EfficientNetB2	36 MB	0.801	0.949	9,177,569	-
EfficientNetB3	48 MB	0.816	0.957	12,320,535	-
EfficientNetB4	75 MB	0.829	0.964	19,466,823	-
EfficientNetB5	118 MB	0.836	0.967	30,562,527	-
EfficientNetB6	166 MB	0.84	0.968	43,265,143	-
EfficientNetB7	256 MB	0.843	0.97	66,658,687	-

Figura 27 - Valores da análise de Modelos Pré-Treinados [33]

Estes quatro modelos foram selecionados devido a serem os 4 mais populares, eficazes e eficientes para resolução de problemas de *computer vision*.

Estes foram desenvolvidos usando *transfer learning*. Esta técnica tem o intuito de transferir o conhecimento anteriormente ganho através de uma certa tarefa possa ser aplicado a uma outra tarefa que seja de certo modo semelhante. Por exemplo, o conhecimento adquirido para reconhecer, por exemplo, bolas desportivas em geral, possa ser útil para a tarefa de classificação de diferentes tipos de bolas [38].

Inicialmente, o modelo é carregado com os pesos anterior calculados. Contudo, todas as camadas são congeladas, e é criada uma última camada através da camada de saída do modelo anteriormente carregado e, posteriormente, o modelo procede com as fases de treino.

4.6.1 Análise dos Resultados

Tabela 12 - Configuração (Validação - Fire)

Modelos	Precisão Treino	Loss Treino	Precisão Validação	Loss Validação	Parâmetros
InceptionV3	97,66%	0,10	95,54%	0,14	31 240 993
EfficientNet	0,64%	0,32	61,00%	0,28	20 106 404
ResNet50	98,75%	0,07	93,21%	0,38	23 589 761
VGG-16	92,42 %	0,21	84,00%	0,45	27 560 764
DetFireNet	97,75%	0,05	89,43%	0,44	10 007 042

Com base nos resultados apresentados na Tabela 12, correspondentes a cada um dos modelos desenvolvidos, é possível verificar que o modelo com os melhores resultados, para este caso com este *dataset*, é o modelo pré-treinado com o *InceptionV3*. Este sistema, em comparação com os outros, apresenta uma maior precisão e consegue detetar e identificar mais facilmente os diversos casos quando comparado com os outros. Contudo, este modelo apresenta um constrangimento, que é devido ao facto de o *InceptionV3* possuir um maior número de parâmetros em relação aos restantes, demorando mais tempo na tarefa de treino.

Neste subcapítulo, estão representadas diferentes situações para as quais foi pedido ao modelo que fizesse a sua previsão. Estas imagens vão tentar ser classificadas em 2 grupos distintos, *Fire* e *NoFire*, sendo que o valor *True* retornado pelo modelo representa a classe *Fire*, e o valor *False* representa a classe *NoFire*.



Figura 28 - Exemplo de presença de fogo

A Figura 28, representa um dos vários exemplos presentes no *dataset* usados para a identificação de incêndios.

```
import numpy as np
from google.colab import files
from keras.preprocessing import image

uploaded = files.upload()
for fn in uploaded.keys():
    path = '/content/' + fn
    img = image.load_img(path, target_size=(224, 224))
    x = image.img_to_array(img)
    x = np.expand_dims(x, axis=0) /255
    classes = model.predict(x)
    print(np.argmax(classes[0])==0, max(classes[0]))
```

Choose Files 960x0 (1).jpg
• 960x0 (1).jpg(image/jpeg) - 25210 bytes, last modified: 4/12/2022 - 100% done
Saving 960x0 (1).jpg to 960x0 (1).jpg
True 0.87989247

Figura 29 - Exemplo da identificação do sistema acerca da Figura 30



Figura 30 - Exemplo de presença de fumo de um incêndio

A Figura 30, representa um dos vários exemplos presentes no *dataset* usados para a identificação de incêndios através da presença de fumo de um incêndio sem a presença visual de fogo na imagem.

```

import numpy as np
from google.colab import files
from keras.preprocessing import image

uploaded = files.upload()
for fn in uploaded.keys():
    path = '/content/' + fn
    img = image.load_img(path, target_size=(224, 224))
    x = image.img_to_array(img)
    x = np.expand_dims(x, axis=0) / 255
    classes = model.predict(x)
    print(np.argmax(classes[0])==0, max(classes[0]))

```

Choose Files istock_100...ire_safety.jpg

- istock_100319_003_wildfire_safety.jpg(image/jpeg) - 103382 bytes, last modified: 4/12/2022 - 100% done

Saving istock_100319_003_wildfire_safety.jpg to istock_100319_003_wildfire_safety.jpg
True 0.93131715

Figura 31 - Exemplo do reconhecimento do sistema acerca da Figura 32



Figura 32 - Exemplo de presença de um pôr do sol

A Figura 32, representa um dos exemplos presentes no *dataset* usados para a verificar que o sistema sabe identificar a presença ou não de incêndios sem ambiguidade os incêndios. Como é possível verificar o resultado presente na Figura 33, este reconhece esta imagem como pertence à classe *NoFire*, conseguindo ultrapassar com sucesso um dos problemas associados à identificação de incêndios, o por do sol.

```
import numpy as np
from google.colab import files
from keras.preprocessing import image

uploaded = files.upload()
for fn in uploaded.keys():
    path = '/content/' + fn
    img = image.load_img(path, target_size=(224, 224))
    x = image.img_to_array(img)
    x = np.expand_dims(x, axis=0) / 255
    classes = model.predict(x)
    print(np.argmax(classes[0])==0, max(classes[0]))
```

astronomia-... 8.png.webp

- astronomia-4-luglio-la-terra-nel-punto-piu-lontano-dal-sole-afelio-2020-261651-1_768.png.webp(image/webp) - 27736 bytes, last modified: 4/12/2022 - 100% done

Saving astronomia-4-luglio-la-terra-nel-punto-piu-lontano-dal-sole-afelio-2020-261651-1_768.png.webp to astronomia-4-luglio-la-terra-nel-punto-piu-lontano-dal-sole-afelio-2020-261651-1_768.png (1).webp
False 0.9144257

Figura 33 - Exemplo do reconhecimento do sistema acerca da Figura 34



Figura 34 - Exemplo da presença de um campo florestal

A Figura 34, representa um dos vários exemplos presentes no *dataset* usados para a verificar que o sistema sabe identificar a presença de ambientes florestais como pertence à classe *NoFire*.

```

import numpy as np
from google.colab import files
from keras.preprocessing import image

uploaded = files.upload()
for fn in uploaded.keys():
    path = '/content/' + fn
    img = image.load_img(path, target_size=(224, 224))
    x = image.img_to_array(img)
    x = np.expand_dims(x, axis=0) / 255
    classes = model.predict(x)
    print(np.argmax(classes[0])==0, max(classes[0]))
  
```

Choose Files 18566281_If4wH.jpeg

- 18566281_If4wH.jpeg(image/jpeg) - 499104 bytes, last modified: 4/12/2022 - 100% done

Saving 18566281_If4wH.jpeg to 18566281_If4wH (1).jpeg
False 0.9984301

Figura 35 - Exemplo do reconhecimento do sistema acerca da Figura 36



Figura 36 - Exemplo da presença de fumo

A Figura 36, representa um dos exemplos presentes no *dataset* usados para a verificar que o sistema sabe identificar a presença ou não de incêndios sem ambiguidade os incêndios. Como é possível verificar o resultado presente na Figura 33, este reconhece esta imagem como pertence à classe *NoFire*, ultrapassando um dos vários problemas associados ao reconhecimento de incêndios, os fumos e nevoeiros.

```
import numpy as np
from google.colab import files
from keras.preprocessing import image

uploaded = files.upload()
for fn in uploaded.keys():
    path = '/content/' + fn
    img = image.load_img(path, target_size=(224, 224))
    x = image.img_to_array(img)
    x = np.expand_dims(x, axis=0) / 255
    classes = model.predict(x)
    print(np.argmax(classes[0])==0, max(classes[0]))
```

Choose Files fumaca-bra...708-359.jpg

- fumaca-branca-espessa-saindo-da-chamine-da-sala-da-caldeira_262708-359.jpg(image/jpeg) - 25027 bytes, last modified: 4/12/2022 - 100% done

Saving fumaca-branca-espessa-saindo-da-chamine-da-sala-da-caldeira_262708-359.jpg to fumaca-branca-espessa-saindo-da-chamine-da-sala-da-caldeira_262708-359 (1).jpg

False 0.9890898

Figura 37 - Exemplo do reconhecimento do sistema acerca da Figura 38

Estes exemplos acima indicados, Figura 28, 30, 32, 34 e 36 são apenas um dos vários exemplos presentes na validação. Como é possível observar verificando o resultado da previsão presente nas Figuras 29, 31, 33, 35 e 37, o modelo é capaz de reconhecer com sucesso estes diversos casos.

Os resultados obtidos configuraram-se acima do esperado. Em primeiro lugar, não só o grau de eficácia e precisão como também as expectativas em relação ao desempenho do modelo eram, numa fase inicial, bastante mais baixas, comparativamente com os resultados que se obtiveram posteriormente. Em segundo lugar, tal como amplamente demonstrado neste subcapítulo, conseguimos ultrapassar diversas dificuldades relativas ao problema em questão, nomeadamente no que concerne à identificação de fumo de incêndio como "Fire", assim como a identificação de nevoeiro como "Nofire".

Assim, o valor de precisão obtido por parte do sistema é bastante satisfatório, considerando o facto de não termos acesso ao *dataset*. Isto influenciou definitivamente o curso deste trabalho, considerando que a quantidade de dados seria bastante superior assim como o facto de estes serem mais realistas.

5 Conclusão

Sintetizando o que foi referido inicialmente, os incêndios florestais são desastres naturais com consequências devastadoras, nomeadamente em Portugal. Por isso, o tempo de resposta das autoridades em situação crítica é decisivo e quanto mais rápida for a sua identificação, maior probabilidade há de extingui-los.

Não obstante o facto de todos os anos Portugal lidar com esta calamidade, a verdade é que não se tem conseguido apresentar uma solução que demonstre resultados satisfatórios.

A partir dos dados fornecidos no portal da EFFIS, conclui-se que Portugal lidera a lista de países da União Europeia no que diz respeito à percentagem de área ardida, durante o período compreendido entre 2006 e 2021. De forma mais precisa, ardeu 1.0517% da sua área. Relativamente aos dados que dizem respeito ao número de ocorrências de fogos florestais, também é possível concluir que Portugal ocupa o segundo lugar desta classificação, tendo 203 fogos florestais, enquanto o primeiro classificado, Itália, possui 263 [28].

Deste modo, verifica-se que Portugal, relativamente aos diferentes países constituintes da União Europeia, apresenta valores bastante negativos e preocupantes, tanto na ocorrência de fogos florestais, como também na frequência com que estes acontecem e na percentagem da área nacional ardida.

Tendo em conta este problema, esta dissertação explora o desenvolvimento de uma solução que possa ajudar a contribuir na diminuição do tempo de resposta envolvido aquando da ocorrência de um fogo florestal, tempo este bastante crucial e determinante para o sucesso do combate a um incêndio.

Neste sentido, foi escolhido o desenvolvimento de uma rede neuronal convolucional como uma forma de contribuir para combater o problema da deteção dos incêndios. Estas têm sido bastantes usadas e têm ganhado cada vez mais popularidade devido a sua eficiência revelada em algumas tarefas de classificação de imagens e *computer vision*.

Com o objetivo de desenvolver uma *CNN* que fosse capaz de identificar eficazmente e ultrapassar problemas associados à identificação de incêndios florestais, o *dataset* foi constituída com recurso a diversos exemplos. Esta deveria englobar diferentes cenários nos

quais os incêndios poderiam ocorrer futuramente, para esta ser capaz de lidar com os mesmos. Sendo assim, o *dataset* foi constituída com diversas imagens de: fogos florestais durante o dia e durante a noite, florestas e ambientes verdes, montanhas, diversos cenários de pôr de sol, nuvens, nevoeiro, fumo de incêndio, entre outras situações. No final deste processo, o *dataset* possuía 3580 exemplos.

Relativamente à fase de desenvolvimento, com o intuito de criar o melhor modelo possível, foram desenvolvidos cinco modelos, para que no futuro fosse possível a escolha do mais eficaz a partir dos anteriormente realizados. Quatro desses cinco modelos são modelos pré-treinados. Modelos pré-treinados são modelos que, dado que foram treinados anteriormente com o *dataset* distribuído e, uma vez que possuem boas arquiteturas, permitem alcançar resultados mais eficazmente, mesmo não utilizando tanta informação. Os quatro modelos pré-treinados usados são os seguintes: *InceptionV3*, *EfficientNet*, *ResNet50* e *VGG-16*.

Os resultados dos diferentes modelos foram recolhidos e colocados na Tabela 5 com os vários elementos de classificação e avaliação, concluindo-se que o melhor modelo desenvolvido é o modelo pré-treinado que faz recurso ao *InceptionV3*. Este modelo apresenta uma precisão de 95,54%, bastante acima das expetativas iniciais.

Umas das várias dificuldades deste processo, e que constituiu um obstáculo que foi necessário ultrapassar, foi a não discrepância entre nevoeiro e fumo proveniente de um incêndio, para além de nuvens, e a indiferença perante a existência de fogo e a ocorrência de um pôr do sol, razão pela qual a presença destes exemplos existe na class *NoFire*.

De modo a alcançar resultados mais positivos e numa perspetiva de melhoramento, seria interessante analisar e testar novos modelos, tirando partido da *data augmentation*. O uso da *data augmentation* poderia ser benéfico e auxiliar na tarefa da composição do *dataset*. Também ajuda na redução de *overfitting* durante as fases de treino e contribui para melhorar os resultados do modelo, devido a possibilitar a existência de muitos mais registos com novas perspetivas e novos casos, compondo, portanto, uma maior e mais preenchida coleção de exemplos e casos de treino.

Para além disso, a existência de uma maior coleção de dados com uma maior diversidade de novos casos de estudo em diferentes ambientes ajudaria a proporcionar uma maior chance de treinar mais facilmente o modelo.

Esta dissertação contribui para o desenvolvimento do conhecimento nesta área, podendo funcionar como um ponto de partida para a expansão e otimização de outros modelos.

Em primeiro lugar, permite identificar automaticamente incêndios com sucesso, num projeto singular sem muitos recursos. Em segundo lugar, ajuda as entidades responsáveis a tomar contacto com diferentes alternativas que podem ser exploradas no combate ao incêndio.

Além disso, contribuiu para perceber este sistema como uma solução ou um passo correto na prevenção e combate de um problema recorrente.

Em jeito de conclusão, esta dissertação pode demonstrar-se relevante como um caso de estudo das potencialidades de novas aplicações e sistemas informáticos que podem apoiar a defesa anti-incêndio.

5.1 Trabalho futuro

O desenvolvimento de sistemas com inteligência artificial continua a diversificar-se e a aumentar rapidamente. *Data augmentation* é uma técnica que pode ser uma boa forma de ajudar a combater e a ser uma ferramenta útil para contornar os diversos desafios existentes no mundo da inteligência artificial.

Para construir um modelo, uma das etapas fundamentais e cruciais neste sistema é o processo de recolha e classificação de dados.

Esta técnica consiste em aumentar a quantidade de dados disponíveis presentes, com a adição de novas cópias ligeiramente modificadas através de dados já anteriormente existentes. Para a criação destes novos registos, através de outros anteriormente existentes, são utilizados e aplicados diversos processos, como por exemplo: rotação da imagem, translação, redimensionamento da imagem, inversão da mesma, aplicação de um filtro preto-branco, modificação de propriedades de cor (contraste, saturação, luminosidade), entre outros.




Figura 38 - Exemplo de data augmentation [31]

Esta técnica ajuda no processo de recolha e classificação de dados, acabando por, consequentemente, reduzir os custos operacionais diretamente relacionados com estas operações. Para além disso, ajuda a reduzir o *overfitting* durante as fases de treino. É também útil para melhorar o desempenho e os resultados do modelo, porque ajuda no processo de formação de novos e diferentes exemplos. Assim, permite com que o modelo seja mais rico e, consequentemente, possua uma melhor precisão e desempenho.

Deste modo, pode ser efetuado o recurso a esta técnica num trabalho futuro. A *data augmentation* pode vir a ser crucial no processo de construção dos dados a ser usados pelo sistema, vindo a reduzir a complexidade da tarefa de constituir ou reunir diferentes exemplos. Para além disso, seria possível reduzir o *overfitting* e, desta forma, melhorar o desempenho do modelo.

Contudo, a obtenção de um maior e mais rico *dataset* com maior número de exemplos e diversos cenários reais, ajudaria a montar o sistema o mais realista possível.

Referências

- [1] Chaochao Lu et al, 2014, "Surpassing Human Level Face Recognition"
- [2] Alexey Ivakhnenko et al (1967). "Cybernetics and Forecasting Techniques"
- [3] Fukushima, 1980, "Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position".
- [4] LeCun, 1989, "Backpropagation Applied to Handwritten Zip Code Recognition"
- [5] Bredan J. et al, 1995, "The wake-sleep algorithm for unsupervised neural networks"
- [6] Sepp Hochreiter; et al. 2001, "Gradient flow in recurrent nets: the difficulty of learning long-term dependencies"
- [7] Raina, Rajat et al, 2009, "Large-scale Deep Unsupervised Learning Using Graphics Processors".
- [8] Ciresan et al., 2012, "Multi-column deep neural networks for image classification"
- [9] Fukushima, 1988, "A hierarchical neural network capable of visual pattern recognition".
- [10] Girshick et al 2014, "Rich feature hierarchies for accurate object detection and semantic segmentation"
- [11] Ciclope, 2022. URL <https://www.ciclope.pt> (accessed 20.2.22).
- [12] YOLO, 2022. URL <https://towardsdatascience.com/yolo-you-only-look-once-3dbdbb608ec4> (accessed 22.2.22).
- [13] YOLO versions, 2022. URL <https://medium.com/@venkatakrishna.jonnalagadda/object-detection-yolo-v1-v2-v3-c3d5eca2312a> (accessed 24.2.22).
- [14] Redmon et al 2015, "You Only Look Once: Unified, Real-Time Object Detection"
- [15] Shaoqing Ren et al 2016, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks"

- [16] <https://towardsdatascience.com/deep-learning-3-more-on-cnns-handling-overfitting-2bd5d99abe5d>
- [17] <https://www.pyimagesearch.com/2021/05/14/convolutional-neural-networks-cnns-and-layer-types/>
- [18] <https://pytorch.org/docs/stable/generated/torch.nn.ReLU.html>
- [19] https://keras.io/api/layers/regularization_layers/dropout/
- [20] <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-019-0192-5>
- [21] <https://towardsdatascience.com/yolo-you-only-look-once-3dbdbb608ec4>
- [22] <https://towardsdatascience.com/r-cnn-fast-r-cnn-faster-r-cnn-yolo-object-detection-algorithms-36d53571365e>
- [23] <https://epssarteam.vr-sar.org/node/875>
- [24] <https://medium.com/@duanenielsen/deep-learning-cage-match-max-pooling-vs-convolutions-e42581387cb9>
- [25] https://arquivo.pt/noFrame/replay/20070607001145/http://www.portugal.gov.pt/NR/rdonlyres/F2960733-D2A0-4667-85B1-6E742FC520D6/0/Livro_Branco_Fogos_Florestais.pdf
- [26] <https://www.v7labs.com/blog/overfitting#what-is-overfitting>
- [27] <https://effis.jrc.ec.europa.eu/about-effis>
- [28] <https://effis.jrc.ec.europa.eu/apps/effis.statistics/estimates>
- [29] <https://www.globalforestwatch.org/blog/data-and-research/global-tree-cover-loss-data-2019/>
- [30] <https://www.globalforestwatch.org/blog/data-and-research/global-tree-cover-loss-data-2021/>
- [31] https://www.researchgate.net/figure/Data-augmentation-using-semantic-preserving-transformation-for-SBIR_fig2_319413978

- [32] <https://www.icnf.pt/api/file/doc/82022cfe3a10f2e3>
- [33] <https://towardsdatascience.com/4-pre-trained-cnn-models-to-use-for-computer-vision-with-transfer-learning-885cb1b2dfc>
- [34] <https://towardsdatascience.com/what-is-machine-learning-a-short-note-on-supervised-unsupervised-semi-supervised-and-aed1573ae9bb>
- [35] <https://towardsdatascience.com/what-is-the-softmax-function-teenager-explains-65495eb64338>
- [36] <https://www.analyticsvidhya.com/blog/2021/06/the-challenge-of-vanishing-exploding-gradients-in-deep-neural-networks/>
- [37] https://moodle.isep.ipp.pt/pluginfile.php/147879/mod_resource/content/1/TMDEI_AULA1.pdf
- [38] https://www.tensorflow.org/tutorials/images/transfer_learning
- [39] <https://keras.io/api/applications/inceptionv3/>
- [40] <https://keras.io/api/applications/resnet/>
- [41] <https://keras.io/api/applications/vgg/>
- [42] <https://keras.io/api/applications/efficientnet/>
- [43] <https://www.publico.pt/2014/10/07/local/noticia/sistema-de-deteccao-de-incendios-nogeres-emitiu-mais-de-1300-falsos-alarmes-1672159>
- [44] <http://www.bee2firedetection.com/pt/#solution>